

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

УДК 004.8

Отчет об исследовательском проекте на тему:
**Оценка границ применимости современных VLM для автоматического
извлечения физических характеристик 2D-сцен**
(промежуточный, этап 1)

Выполнили студенты:

группы #БПМИ234, 3 курса

Баранова Елизавета Сергеевна

группы #БПМИ234, 3 курса

Маркотенко Александр Евгеньевич

Принял руководитель проекта:

Бурлова Альбина Сергеевна,

старший преподаватель Департамента больших данных и информационного поиска

Факультет компьютерных наук НИУ ВШЭ

Содержание

Аннотация	3
1 Введение	4
1.1 Описание предметной области	4
1.2 Постановка задачи	4
1.3 Актуальность и значимость	5
1.4 Планируемые результаты	5
2 Основные термины и используемые методы	6
3 Обзор и анализ литературы	8
4 План работы и распределение задач	9
5 Глава 1. Постановка задачи и протокол оценки	10
5.1 Объектно-ориентированная постановка	10
5.2 Набор физических характеристик	11
5.3 Формат разметки и структура данных	12
5.4 Режимы подачи визуального входа	13
5.5 Протокол инференса zero-shot и few-shot	13
5.6 Zero-shot	13
5.7 Few-shot	14
5.8 Метрики качества	14
5.8.1 Accuracy	14
5.8.2 Macro-F1	14
5.8.3 Селективная оценка с учётом unknown	14
5.9 Выводы по главе	15
Список литературы	16

Аннотация

Проект посвящён исследованию способности современных vision–language моделей (VLM) автоматически извлекать физические характеристики объектов и сцен, такие как материал, фактура, хрупкость, теплопроводимость и другие свойства, релевантные задачам взаимодействия с объектами. В рамках работы предполагается разработка и экспериментальная оценка протокола мультимодального анализа физических свойств, который может быть использован в качестве компонента пайплайна подготовки данных для обучения vision–language–action (VLA) систем, ориентированных на взаимодействие с объектами с учётом их физических качеств.

Ключевые слова

VLM, физические свойства объектов, извлечение атрибутов, подготовка данных, VLA-системы, машинное обучение.

1 Введение

1.1 Описание предметной области

Современные Vision-Language Models (VLM) представляют собой класс мультимодальных моделей, предназначенных для совместной обработки визуальной и текстовой информации. Такие модели принимают на вход изображение и текстовый запрос и формируют ответ в текстовой форме, что позволяет использовать их для широкого круга задач визуального анализа без необходимости явного переобучения под каждую конкретную постановку. За счёт этого VLM активно применяются как универсальный инструмент анализа изображений в прикладных и исследовательских задачах.

Одним из направлений применения VLM является извлечение физических характеристик сцен по изображениям. В рамках данной работы под физическими характеристиками 2D-сцен понимаются параметры, интерпретируемые как свойства объектов и их взаимного расположения в реальном мире, такие как относительные размеры и расстояния, геометрические соотношения, ориентация объектов, признаки формы и материала, а также производные оценки, основанные на визуальных признаках сцены. Подобные характеристики востребованы в задачах анализа окружающей среды, взаимодействия с визуальными данными и поддержки принятия решений на основе изображений.

В отличие от специализированных моделей компьютерного зрения, обученных на конкретный тип физического выхода (например, карты глубины или сегментацию), VLM потенциально позволяют получать такие характеристики в формате ответов на естественно-языковые запросы. Однако извлечение физических параметров из одиночных 2D-изображений связано с фундаментальными ограничениями, обусловленными неполной наблюдаемостью сцены, отсутствием информации о масштабе и параметрах съёмки, а также неоднозначностью визуальной интерпретации. В связи с этим возникает необходимость систематической оценки границ применимости современных VLM для задач автоматического извлечения физических характеристик 2D-сцен.

1.2 Постановка задачи

Рассматривается задача автоматического извлечения физически интерпретируемых характеристик объектов и сцен по одиночным 2D-изображениям с использованием современных vision-language моделей (VLM). В рамках работы под физическими характеристиками понимается набор атрибутов, выводимых на основе визуальных признаков сцены и потен-

циально используемых при взаимодействии с объектами, включая (но не ограничиваясь) материал, фактуру поверхности, хрупкость, а также геометрические и пространственные соотношения (относительные размеры, взаимное расположение, ориентация).

Цель работы — разработать и экспериментально оценить воспроизводимый протокол применения VLM для извлечения указанных характеристик, а также определить границы применимости такого подхода.

Особое внимание уделяется анализу фундаментальных ограничений постановки, обусловленных неполной наблюдаемостью 3D-сцены при её проекции в 2D, отсутствием информации о масштабе и параметрах съёмки, а также неоднозначностью визуальной интерпретации, что может приводить к множественности допустимых объяснений наблюдаемой сцены.

1.3 Актуальность и значимость

Актуальность и значимость данной работы связаны с тем, что Vision-Language Models всё чаще используются для анализа изображений в формате ответов на текстовые запросы, включая задачи, предполагающие получение физически интерпретируемых характеристик сцены. При этом условия корректности и устойчивости таких ответов при работе с одиночными 2D-изображениями остаются недостаточно изученными. Планируемое исследование границ применимости современных VLM позволит уточнить, в каких сценариях такие модели могут использоваться для извлечения физических характеристик, а в каких их применение требует дополнительных ограничений или проверок, что представляет практический и методологический интерес для задач мультимодального анализа визуальных данных.

1.4 Планируемые результаты

В рамках данной работы планируется провести систематическое экспериментальное исследование современных Vision-Language Models в задаче извлечения физических характеристик 2D-сцен. В качестве базового результата предполагается сформировать единый воспроизводимый пайплайн инференса, позволяющий применять выбранные компактные SOTA-модели в унифицированном формате и проводить их сравнение в контролируемых условиях. Пайплайн будет включать стандартизированную обработку входных данных, формирование текстовых запросов, сбор ответов моделей и последующую оценку качества.

Планируется получить сравнительную оценку качества zero-shot и few-shot инференса для выбранного набора моделей по различным классам физических характеристик. Для этого предполагается формализовать постановку задачи, включая список целевых физических

свойств, формат разметки и метрики оценки, а также определить единый протокол экспериментов. Ожидается, что результаты позволят выявить различия в поведении моделей при изменении режима инференса и степени предоставляемого контекста.

Отдельным направлением планируемых экспериментов является анализ влияния сегментации объектов. Предполагается сравнить качество извлечения физических характеристик при подаче модели полного изображения и при использовании объектных масок, выделяющих отдельные элементы сцены. Это позволит оценить, в какой степени явное указание области интереса снижает неоднозначность интерпретации сцены и влияет на устойчивость ответов VLM.

Для нескольких наиболее показательных моделей планируется исследовать эффект дообучения на части данных с разметкой физических свойств. Предполагается сравнить качество моделей до и после дообучения, а также проанализировать, какие типы физических характеристик и сцен в наибольшей степени выигрывают от такого подхода. Эти эксперименты направлены на оценку практической целесообразности дообучения VLM в данной постановке задачи.

Планируемая новизна работы заключается в комплексном анализе границ применимости современных VLM для извлечения физических характеристик 2D-сцен. В отличие от работ, ориентированных на отдельные свойства или конкретные модели, предполагается провести сопоставление нескольких факторов одновременно, включая режим инференса (zero-shot/few-shot), использование сегментации, схемы дообучения и типы входных данных. Дополнительно планируется сформулировать воспроизводимый протокол оценки и набор практических рекомендаций по использованию и дообучению VLM, а при наличии ресурсов — сформировать пилотный датасет физических свойств объектов на базе открытых данных с ручной валидацией.

2 Основные термины и используемые методы

В данном разделе кратко вводятся основные термины и методы, используемые в работе, необходимые для понимания постановки задачи и экспериментальной части.

- **Vision–Language модели (VLM)** — мультимодальные модели, обученные на парах изображение–текст и формирующие совместные представления визуальной и текстовой информации.
- **Физические характеристики объектов и сцен** — свойства объектов, определяю-

щие их поведение при взаимодействии, включая материал, фактуру поверхности, хрупкость, теплопроводимость и другие атрибуты.

- **zero-shot и few-shot инференс** — режимы применения модели к новой задаче без дополнительного дообучения либо с использованием ограниченного числа размеченных примеров соответственно. Используются для оценки обобщающей способности VLM.
- **Сегментация объектов** — этап предварительной обработки, при котором для изображения выделяются маски отдельных объектов. Используется для анализа влияния фокусировки на отдельных объектах на качество извлечения физических характеристик.
- **Физическое рассуждение** — способность модели делать выводы о физических свойствах и поведении объектов на основе визуальной информации.
- **Мультимодальный запрос (prompt)** — текстовое описание или вопрос, подаваемый на вход VLM совместно с изображением и определяющий тип и формат ожидаемого ответа модели. Формулировка запроса влияет на интерпретацию сцены и извлекаемые физические характеристики.
- **Устойчивость и воспроизводимость ответов** — степень стабильности предсказаний VLM при варьировании формулировок запросов, порядка подачи примеров (в few-shot режиме) и незначительных изменений входных данных. Используется как один из критериев оценки применимости моделей к извлечению физических характеристик.
- **Неоднозначность визуальной интерпретации** — ситуация, при которой физические характеристики сцены не могут быть однозначно восстановлены по одиночному 2D-изображению из-за проекционных эффектов, отсутствия масштаба или скрытых свойств объектов. Рассматривается как фундаментальное ограничение задачи.
- **Протокол оценки** — формализованный набор правил, включающий выбор входных данных, шаблоны запросов, режим инференса (zero-shot / few-shot), метрики качества и процедуры сравнения моделей, обеспечивающий воспроизводимость экспериментальных результатов.

3 Обзор и анализ литературы

Современные исследования в области компьютерного зрения и мультимодального обучения активно изучают способность моделей извлекать и использовать информацию о физических свойствах объектов и сцен. Существующие работы можно условно разделить на несколько направлений: физическое рассуждение в синтетических средах, оценка физических свойств объектов по визуальным данным, а также развитие vision language models (VLM), обученных на масштабных мультимодальных корпусах.

Ранние работы по физическому рассуждению, такие как CLEVRER [5] и PHYRE [6], фокусируются на моделировании физических взаимодействий в контролируемых синтетических сценах. В данных подходах сцены специально сконструированы для проверки способности моделей понимать причинно-следственные связи, столкновения, устойчивость и другие аспекты физики. Несмотря на чёткую постановку задач и интерпретируемые метрики, такие методы слабо масштабируются на реальные изображения и, как правило, не предполагают явного извлечения семантически интерпретируемых физических атрибутов объектов, таких как материал или хрупкость.

Работа Physion [1] расширяет данный подход, предлагая более разнообразные сценарии физических взаимодействий и сравнение предсказаний моделей с человеческими оценками. Однако и в этом случае основной акцент делается на предсказание динамики и физических исходов сцен, а не на извлечение явных физических характеристик объектов, что ограничивает применимость подхода в задачах подготовки данных для обучения систем взаимодействия с объектами.

Отдельное направление связано с оценкой физических свойств объектов по визуальным данным. В частности, в работе [2] показано, что при использовании Neural Radiance Fields возможно восстановление некоторых физических параметров сцены. Тем не менее данный подход требует многовидовых данных и специализированного формата входной информации, что существенно ограничивает его применимость к произвольным 2D-сценам и задачам массовой автоматической разметки.

Параллельно с этим активно развиваются vision-language модели, обученные на больших наборах пар изображение-текст. Базовые работы в этой области, такие как CLIP [3], демонстрируют способность моделей формировать обобщённые мультимодальные представления и успешно переноситься на широкий спектр downstream-задач в режимах zero-shot и few-shot. Однако способность таких моделей к извлечению физических свойств объектов и сцен, как правило, рассматривается лишь косвенно и не является основной целью исследо-

ваний.

Недавние работы, направленные на усиление пространственного и логического рассуждения в VLM, в частности SpaRE [4], показывают улучшения в задачах понимания структуры сцены и взаимного расположения объектов. Тем не менее даже в этих подходах физические характеристики остаются вторичными признаками, а влияние таких факторов, как сегментация объектов или выбор режима инференса (zero-shot, few-shot), изучено недостаточно систематически.

Таким образом, существующие работы либо фокусируются на физическом рассуждении в ограниченных синтетических средах, либо используют специализированные модели и данные, либо рассматривают vision language models без явной оценки их способности извлекать физические характеристики объектов и сцен. Это указывает на отсутствие унифицированного протокола оценки границ применимости современных VLM для задачи автоматического извлечения физических свойств 2D-сцен. Настоящая работа направлена на восполнение данного пробела за счёт систематического сравнения современных VLM в различных режимах инференса, анализа влияния сегментации и исследования характерных ограничений таких моделей.

4 План работы и распределение задач

- Проанализировать литературу по задачам извлечения физических свойств сцен (physical reasoning, material/property estimation) мультимодальными моделями. (Елизавета Баранова)
- Подобрать набор компактных SOTA-моделей (VLM), доступных для инференса на одном GPU уровня A100, и реализовать единый пайплайн вызова. (Александр Маркотенко)
- Сформулировать постановку задачи на базе выбранных данных: определить список физических характеристик, формат разметки, метрики и протокол оценки (zero-shot, few-shot). (Елизавета Баранова)
- Провести серию экспериментов по zero-shot/few-shot инференсу выбранных VLM по извлечению физических свойств. (Александр Маркотенко)
- Оценить влияние сегментации: выделить маски объектов и сравнить качество VLM при подаче масок по сравнению с сырым изображением. (Елизавета Баранова)

- Для отобранных топ-3 моделей исследовать различные варианты дообучения на части данных и сравнить качество до и после. (Александр Маркотенко)
- Проанализировать характер типичных ошибок и границы применимости: в каких типах сцен и свойств модели устойчиво работают, а где систематически ошибаются. (Елизавета Баранова)
- (В идеале) На базе одного или нескольких открытых наборов данных построить пилотный датасет с разметкой физических свойств объектов, используя разработанный пайплайн и ручную валидацию предсказаний моделей. (Александр Маркотенко)

5 Глава 1. Постановка задачи и протокол оценки

Целью работы является систематическая оценка границ применимости современных vision-language моделей для автоматического извлечения физических характеристик объектов на статических 2D-изображениях сцен. В рамках данной главы формализуется постановка задачи, фиксируется набор предсказываемых свойств, формат разметки, протоколы инференса (zero-shot, few-shot) и метрики качества.

5.1 Объектно-ориентированная постановка

Рассматривается объектно-ориентированная постановка, в которой единицей анализа является объект o на изображении I . Для каждого объекта задана локализация (например, ограничивающая рамка) и, при наличии, пиксельная маска.

Пусть I — изображение сцены, o — целевой объект на I , $B(o)$ — ограничивающая рамка объекта, $M(o)$ — маска объекта. Требуется построить процедуру инференса VLM, которая по входу (I, o) предсказывает набор физических характеристик объекта:

$$\hat{\mathbf{y}}(o) = (\hat{y}_1(o), \dots, \hat{y}_K(o)),$$

где каждый компонент $\hat{y}_k(o)$ соответствует фиксированному физическому свойству (например, материал, прозрачность и т.д.) и принимает значение из заранее заданного конечного множества меток.

Объектно-ориентированная формулировка позволяет:

- оценивать качество извлечения свойств для конкретных объектов независимо от фонового контекста;

- корректно сравнивать режимы подачи визуального входа (исходное изображение, стор, маска) в рамках единого протокола;
- проводить детальный анализ ошибок по типам объектов и условиям сцены.

5.2 Набор физических характеристик

Для оценки выбирается набор характеристик, которые частично наблюдаемы по 2D-изображению и при этом отражают как относительно простые, так и пограничные аспекты физических свойств. Для каждого свойства допускается значение **unknown**, означающее, что по данному изображению свойство нельзя определить с достаточной обоснованностью.

Далее используется следующий набор свойств:

- 1 **Материал** (**material**) — мультиклассовая классификация по словарю: {**metal**, **wood**, **glass**, **plastic**, **fabric**, **paper/cardboard**, **ceramic/stone**, **rubber**, **leather**, **other**, **unknown**}.
- 2 **Прозрачность** (**transparency**): {**opaque**, **translucent**, **transparent**, **unknown**}.
- 3 **Блеск/отражательность** (**reflectance**): {**matte**, **glossy**, **unknown**}.
- 4 **Шероховатость поверхности** (**surface_roughness**): {**smooth**, **rough**, **unknown**}.
- 5 **Жёсткость** (**rigidity**): {**rigid**, **deformable**, **unknown**}.
- 6 **Хрупкость** (**fragility**): {**fragile**, **not_fragile**, **unknown**}.
- 7 **Влажность** (**wetness**): {**wet**, **dry**, **unknown**}.
- 8 **Состояние поверхности** (**state**): {**clean**, **dirty**, **unknown**}.
- 9 **Оценка веса** (**weight_hint**) — пограничное свойство: {**light**, **heavy**, **unknown**}.
- 10 **Температура (визуальная подсказка)** (**temperature_hint**) — пограничное свойство, определяемое по косвенным визуальным признакам (пар, конденсат, лёд и т.п.): {**hot**, **cold**, **room**, **unknown**}.
- 11 **Агрегатное состояние вещества** (**phase**) — актуально для содержимого/частей объекта и сцен с жидкостями/льдом: {**solid**, **liquid**, **gas**, **unknown**}.
- 12 **Наличие жидкости/наполненность** (**filled_state**) — для контейнеров (стакан, бутылка, чашка): {**empty**, **partially_filled**, **filled**, **unknown**}.

13 **Скользкость (оценочная)** (`slipperiness_hint`) — пограничное свойство, связанное с материалом и состоянием поверхности: `{slippery, not_slippery, unknown}`.

Значение `unknown` является частью постановки и используется для явного моделирования границ применимости: если свойство не следует из изображения (или определяется неоднозначно), корректным ответом считается `unknown`.

5.3 Формат разметки и структура данных

Датасет представляется в виде набора записей $\mathcal{D} = \{(I_i, o_{ij}, \mathbf{y}_{ij})\}$, где $\mathbf{y}_{ij}$ — вектор истинных меток свойств для объекта o_{ij} на изображении I_i .

Практически удобно хранить разметку в формате JSONL (одна строка на объект). Пример записи:

```
{
  "image_id": "xxx",
  "object_id": 17,
  "category": "bottle",
  "bbox": [x, y, w, h],
  "mask_path": "masks/xxx_17.png",
  "labels": {
    "material": "glass",
    "transparency": "transparent",
    "reflectance": "glossy",
    "surface_roughness": "smooth",
    "rigidity": "rigid",
    "fragility": "fragile",
    "wetness": "unknown",
    "state": "clean",
    "weight_hint": "unknown"
  }
}
```

Для обеспечения воспроизводимости фиксируются следующие правила разметки:

- Размечаются только те свойства, которые можно обосновать визуальными признаками на 2D-изображении; иначе ставится `unknown`.

- В случае смешанных материалов допускается выбор доминирующего материала; при невозможности — **other** или **unknown** в зависимости от видимости признаков.
- Словарь меток фиксирован и используется одинаково для всех моделей и режимов инференса.

5.4 Режимы подачи визуального входа

В целях последующего анализа влияния сегментации фиксируются следующие режимы подачи визуального входа модели:

- 1 **Raw** — исходное изображение объекта, полученное как стоп по $B(o)$.
- 2 **Mask-overlay** — стоп по $B(o)$ с наложением контура/маски $M(o)$.
- 3 **Masked-object** — объект, вырезанный по $M(o)$ и размещённый на нейтральном фоне (при наличии маски).

Данные режимы позволяют сравнивать качество извлечения свойств при различных формах визуального контекста при неизменных текстовых инструкциях.

5.5 Протокол инференса zero-shot и few-shot

Для сопоставимости результатов используется единый формат ответа: модель должна возвращать значения свойств строго из заданных словарей и выдавать результат в виде JSON. При невозможности определить свойство модель должна возвращать **unknown**. При инференсе используются фиксированные параметры генерации (например, температура 0), чтобы минимизировать стохастичность.

5.6 Zero-shot

В режиме zero-shot модель получает только инструкцию, изображение (в одном из режимов из раздела 5.4) и описание требуемого формата ответа. Пример текстовой инструкции:

Тебе дано изображение и выделенный объект. Определи физические характеристики объекта. Выбирай значения строго из списков. Если по изображению нельзя определить - ответь "unknown". Верни только JSON по полям: material, transparency, reflectance, surface_roughness, rigidity, fragility, wetness, state, weight_hint. НАДО ПОМЕНЯТЬ ЭТО ДЛЯ ПРИМЕРА

5.7 Few-shot

В режиме few-shot к инструкции добавляются k демонстрационных примеров вида (вход $\rightarrow$ корректный JSON-ответ), после чего задаётся тестовый объект. Рассматриваются значения $k \in \{1, 2, 4, 8\}$, а набор демонстрационных примеров фиксируется заранее для воспроизводимости.

5.8 Метрики качества

Качество оценивается отдельно по каждому свойству, а также агрегируется по свойствам при необходимости (например, среднее по K характеристикам). Для мультиклассовых свойств используется точность классификации (ассигасу) и макро-F1; дополнительно анализируется поведение на классе `unknown` и селективные метрики.

5.8.1 Accuracy

Для свойства k точность определяется как доля объектов, для которых предсказание совпало с истинной меткой:

$$\text{Acc}_k = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[\hat{y}_k^{(n)} = y_k^{(n)}], \quad (1)$$

где N — число объектов в тестовой выборке, $\mathbb{I}[\cdot]$ — индикатор.

5.8.2 Macro-F1

Для свойства k вычисляется F1-мера отдельно для каждого класса, после чего берётся среднее по классам (макро-F1). Данная метрика менее чувствительна к дисбалансу классов по сравнению с ассигасу.

5.8.3 Селективная оценка с учётом unknown

Для анализа границ применимости вводятся две величины:

- **Покрытие** (coverage) — доля объектов, для которых модель выдала не `unknown`:

$$\text{Cov}_k = \frac{1}{N} \sum_{n=1}^N \mathbb{I}[\hat{y}_k^{(n)} \neq \text{unknown}]. \quad (2)$$

- **Селективная точность** (selective accuracy) — ассигасу на подмножестве объектов, где

модель сделала конкретное предсказание:

$$\text{SelAcc}_k = \frac{\sum_{n=1}^N \mathbb{I}[\hat{y}_k^{(n)} \neq \text{unknown}] \cdot \mathbb{I}[\hat{y}_k^{(n)} = y_k^{(n)}]}{\sum_{n=1}^N \mathbb{I}[\hat{y}_k^{(n)} \neq \text{unknown}]}.$$
 (3)

Пара $(\text{Cov}_k, \text{SelAcc}_k)$ позволяет различать модели, которые предпочитают отвечать всегда (высокое покрытие, но низкая точность), и модели, которые чаще выбирают **unknown**, но дают более надёжные ответы при наличии уверенности.

5.9 Выводы по главе

В главе зафиксирована объектно-ориентированная постановка задачи извлечения физических характеристик по 2D-изображениям, определён словарь свойств и формат разметки, описаны режимы подачи визуального входа (включая варианты с сегментацией), а также задан воспроизводимый протокол инференса в режимах zero-shot и few-shot. Для оценки качества предложены метрики ассигасу и масго-F1, а также селективные метрики coverage и selective ассигасу, позволяющие анализировать границы применимости и склонность моделей к необоснованным предсказаниям.

Список литературы

- [1] Kelsey R. Allen, Kevin A. Smith и Joshua B. Tenenbaum. “Physion: Evaluating Physical Prediction from Vision in Humans and Machines”. В: *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS)* (2021).
- [2] Xingyu Liu, Yilun Du, Joshua B. Tenenbaum и Jiajun Wu. “Physical Property Understanding from Images via Neural Radiance Fields”. В: *arXiv preprint arXiv:2404.04242* (2024).
- [3] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin и Ilya Sutskever. “Learning Transferable Visual Models from Natural Language Supervision”. В: *Proceedings of the International Conference on Machine Learning (ICML)* (2021).
- [4] Yue Yang, Yiming Li и Yixin Zhu. “SpaRE: Enhancing Spatial Reasoning in Vision–Language Models”. В: *arXiv preprint arXiv:2504.20648* (2025).
- [5] Kexin Yi, Chuang Gan, Pushmeet Kohli, Jiajun Wu и Joshua B. Tenenbaum. “CLEVRER: Collision Events for Video Representation and Reasoning”. В: *Proceedings of the International Conference on Learning Representations (ICLR)* (2020).
- [6] Allan Zhou, Vimal Veerapaneni, Mohit Bansal и Jiajun Wu. “Learning Physical Common Sense from Abstract Visual Scenes”. В: *Proceedings of the Conference on Computer Vision and Pattern Recognition (CVPR)* (2019).